# PROJETO DE PESQUISA — TRILHAS DE PTT

Arquitetura e Organização de Computadores · Mestrado Profissional em Computação Aplicada (PPCA/UFRR)

## PARTE I — MODELO A SER PREENCHIDO

**Discente(s):** Filipe Matias e Guilherme Lucas **Dupla? (S/N):** S

**Orientador(a):** Herbert Oliveira Rocha **Semestre:** Segundo

**Prazo:** Onze semanas **Data:** 15/09/2026

**Linha de pesquisa:** X **Sistemas Embarcados/Distribuídos** ☐ **Informática na Educação**

## 1. TÍTULO DO PROJETO (PROVISÓRIO)

Benchmarking de inferência do Yolo quantizado em MCU e SBC: desempenho e eficiência energética em cenários de Edge AI.

## 2. INTRODUÇÃO E JUSTIFICATIVA

### 2.1 Contextualização

A adoção de inferência de redes neurais diretamente em dispositivos de borda (Edge AI) é cada vez mais comum em aplicações de baixo custo e consumo restrito. A escolha entre uma MCU e um SBC como plataforma de execução envolve compromissos entre desempenho, consumo energético e complexidade de desenvolvimento que raramente são quantificados de forma sistemática na literatura acessível a um curso de pós-graduação profissional.

### 2.2 Problema de pesquisa

Como se comparam latência, throughput e energia por inferência entre uma MCU (ESP32 S3) e um SBC (Raspberry Pi Zero 2 W) ao executar o mesmo YOLOX-Nano (quantizado int8) para classificação de EPIs?

### 2.3 Hipótese(s) ou pergunta(s) norteadora(s) (opcional)

H1: o SBC apresenta throughput maior que a MCU, mas com energia por inferência igual ou superior, dado seu consumo estático mais alto.

## 3. OBJETIVOS

### 3.1 Objetivo geral

Comparar sistematicamente desempenho e eficiência energética de inferência de um modelo YOLOX-Nano quantizado em uma MCU e em um SBC representativos do espectro de Edge AI.

### 3.2 Objetivos específicos (3 a 5 itens)

1. Implementar um pipeline de inferência funcionalmente idêntico nas duas plataformas.
2. Medir latência média e throughput de inferência em cada plataforma.
3. Medir (ou estimar, conforme Plano B) a energia consumida por inferência.
4. Comparar a eficiência energética normalizada (inferências por joule) entre as plataformas.

## 4. TRILHA DE PTT ESCOLHIDA

☐ PTT1 — Protótipo de Sistema Ciberfísico (CPS)
☐ PTT2 — IP Core em VHDL
☐ PTT3 — Framework de aceleração paralela (CUDA)
☐ PTT4 — Biblioteca de software embarcado
☐ PTT5 — PoC de coprocessador / extensão de ISA
X PTT6 — Benchmarking e eficiência energética
☐ PTT7 — Controle baseado em FSM
☐ PTT8 — Depósito de patente/registro (INPI)*
☐ PTT9 — Simulador de microarquitetura c/ telemetria
☐ PTT10 — Bancada de lab. remoto FPGA/GPU/MCU
☐ PTT11 — Avaliador automático de assembly

** PTT8 apenas como produto secundário, nunca como principal.*

**Produto principal:** Relatório técnico conclusivo

**Produto secundário:** Dataset publicado (medições brutas no formato CSV)

### 4.1 Justificativa da escolha da trilha

A trilha presente no PTT 6 aborda a temática de Edge AI que será a temática presente nos trabalhos finais dos discentes no Mestrado.

## 5. FUNDAMENTAÇÃO E VÍNCULO COM A EMENTA

O projeto mobiliza os tópicos de desempenho e Lei de Amdahl (comparação de tempos de execução entre arquiteturas), hierarquia de memória e E/S (restrições de memória da MCU frente ao SBC) e, secundariamente, paralelismo (o SBC dispõe de múltiplos núcleos, ainda que não explorados no escopo mínimo).

## 6. METODOLOGIA

### 6.1 Escopo mínimo viável

Inferência de um único modelo (YOLOX-Nano, quantizado em int8) em exatamente duas plataformas — ESP32 (MCU) e Raspberry Pi Zero 2 W (SBC) — com protocolo declarado, 30 repetições por plataforma e medição de energia por medidor inline (ou proxy documentado, conforme Plano B). Utilização de um dataset para classificação de EPIs.

### 6.2 Escopo excluído explicitamente

Comparação com a GPU RTX 3090; uso de múltiplos modelos ou datasets; otimização/tuning da quantização; comparação com inferência em nuvem; implantação em campo prolongada.

### 6.3 Protocolo experimental

**Hipótese(s) testável(is):** H1 (ver item 2.3)

**Variável(is) independente(s):** Plataforma de hardware ESP32 S3 e Raspberry Pi Zero 2 W

**Variável(is) dependente(s):** Latência de inferência (ms); throughput (inferências/s); energia por inferência (mJ)

**Número de repetições e critério de descarte:** 30 execuções por plataforma, após descarte das 5 primeiras (aquecimento)

**Medida de dispersão (ex.: desvio-padrão, IQR):** Desvio-padrão, intervalo interquartil (IQR) e coeficiente de variação

**Instrumentos/ferramentas de medição:** Medidor de potência inline (ex.: INA219) amostrando a 10 Hz; script de cronometragem via toggle de GPIO

**Principal ameaça à validade e mitigação:** Variação térmica ao longo da sessão — mitigada com pausas de resfriamento entre baterias de execução e execuções em ambientes refrigerados com centrais de ar.

## 7. INFRAESTRUTURA NECESSÁRIA

☐ Kit Raspberry Pi Zero W
☐ FPGA + Quartus Prime Lite
☐ Sensores (especificar abaixo)
X ESP32 / Arduino Mega
☐ Estação com GPU RTX 3090

**Outro / especificação:** Raspberry Pi Zero 2 W; medidor de potência inline (INA219); fonte de alimentação regulada

## 8. CRONOGRAMA (15 SEMANAS)

| Fase | Semanas | Atividades principais |
|---|---|---|
| Revisão e protocolo | 1-2 | Revisão bibliográfica; definição final do protocolo experimental |
| Implementação | 3-5 | Pipeline de inferência idêntico nas duas plataformas |
| Execução dos experimentos | 6–9 | Coleta das 30 repetições por plataforma |
| Análise dos dados | 10-11 | Estatística descritiva e comparação entre plataformas |
| Redação do relatório | 12-13 | Relatório técnico conclusivo |
| Vídeo e entrega final | 14-15 | Gravação do vídeo de demonstração e ajustes finais |

## 9. RISCOS E PLANO DE CONTINGÊNCIA

| Risco principal | Probabilidade | Impacto | Plano B |
|---|---|---|---|
| Indisponibilidade/defeito do medidor de potência físico | média | alto | Estimar energia a partir de datasheet e tempo de execução medido, declarando a limitação no relatório |
| Modelo não performar em algum dos dispositivos | média | alto | Utilizar outras versões quantizadas do Yolo |

## 10. RESULTADOS ESPERADOS E ENTREGÁVEIS

### 10.1 Entregáveis-base (obrigatórios para qualquer trilha)

- Repositório versionado com licença
- README de reprodutibilidade
- Dados brutos (CSV com o resultado das execuções)
- Vídeo de demonstração (3–5 min) das execuções nas duas plataformas (ESP32 S3 e Raspiberry Pi Zero 2 W)
- Relatório técnico conclusivo com tabelas e gráficos comparativos

### 10.2 Consolidação pós-disciplina

Submissão a evento regional de sistemas computacionais; publicação do dataset de medições com DOI (Zenodo).

## 11. REFERÊNCIAS BIBLIOGRÁFICAS PRELIMINARES


- Patterson, D. A.; Hennessy, J. L. Computer Organization and Design (edição adotada na disciplina).
- Datasheets das plataformas utilizadas (ESP32; Raspberry Pi Zero 2 W).
- Repositório e readme no GitHub https://github.com/Megvii-BaseDetection/YOLOX


Assinatura do(s) discente(s)

Assinatura do(a) orientador(a)

Documento assinado digitalmente
gov.br
FILIPE MATIAS DE SOUSA
Data: 15/09/2026 21:27:04-0300
Verifique em https://validar.iti.gov.br

Documento assinado digitalmente
gov.br
GUILHERME LUCAS PEREIRA BERNARDO
Data: 15/09/2026 21:30:35-0300
Verifique em https://validar.iti.gov.br