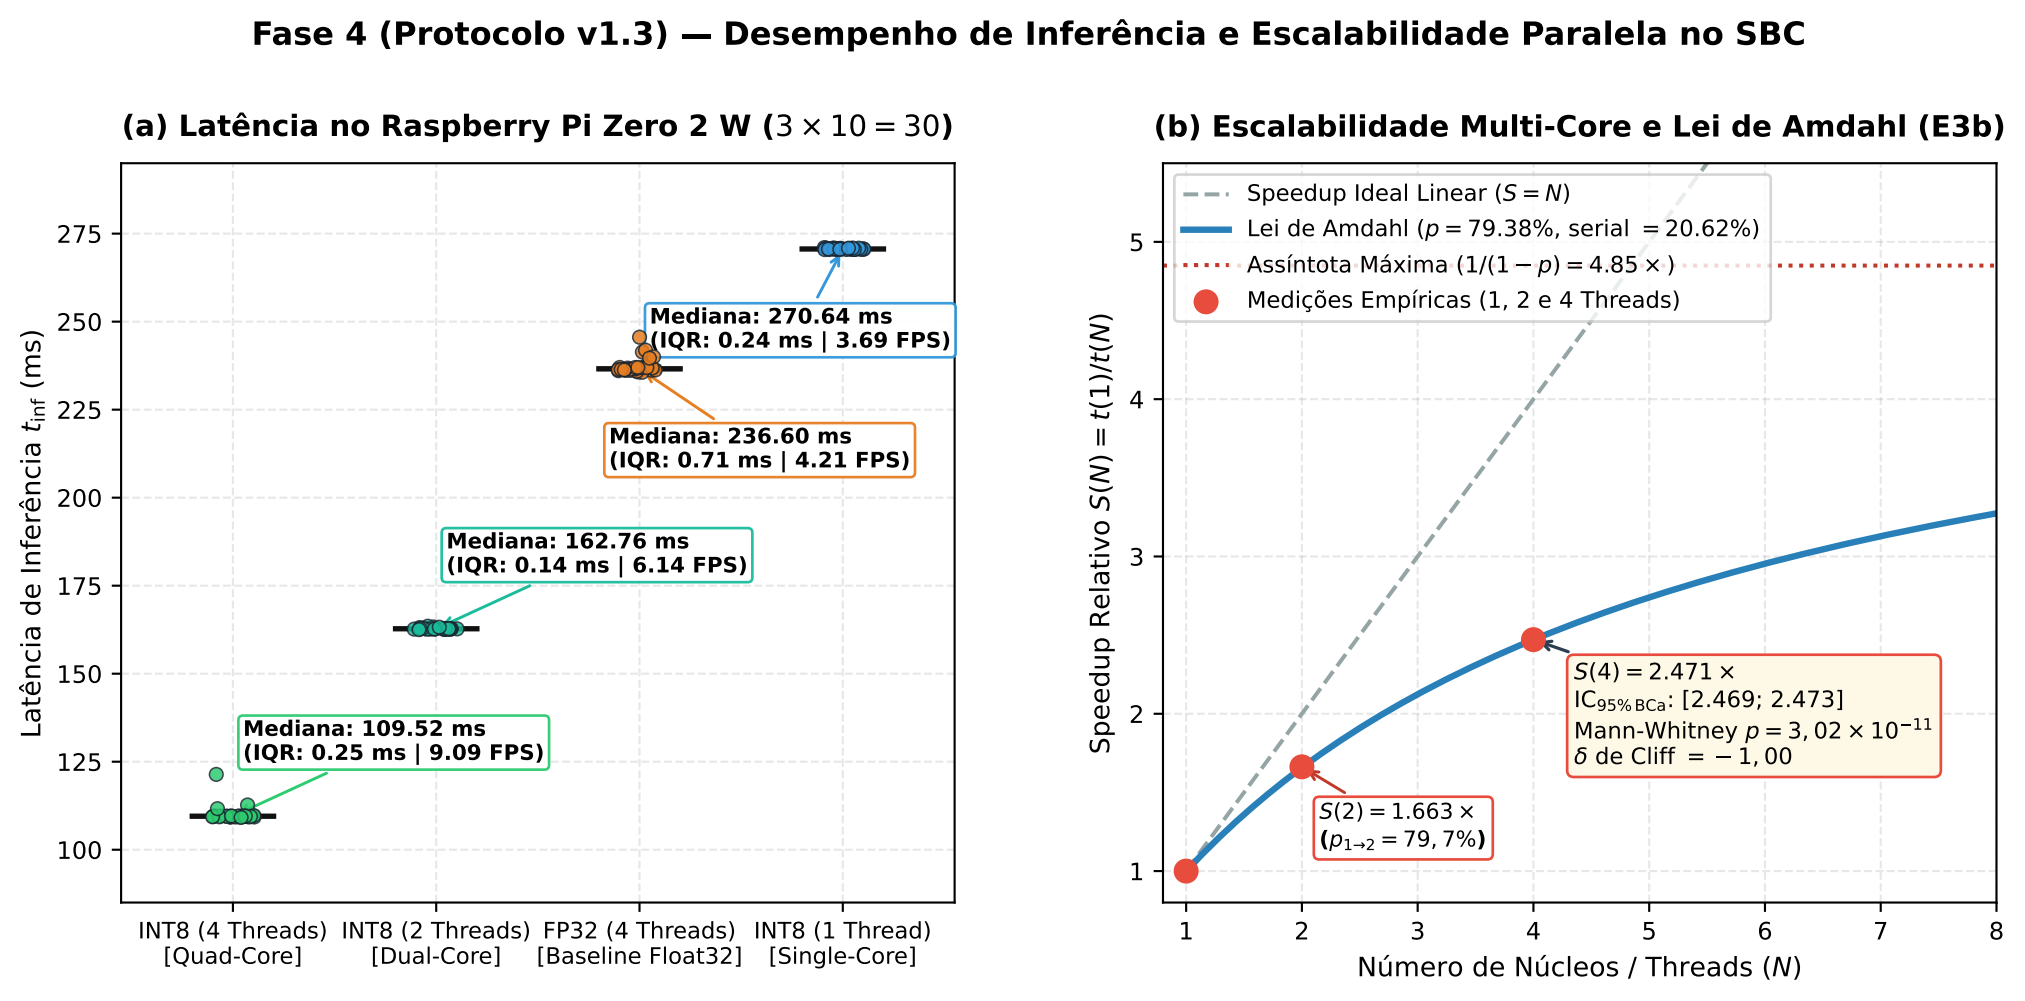
Fase 4 (Protocolo v1.3) — Desempenho de Inferência e Escalabilidade Paralela no SBC
(a) Latência no Raspberry Pi Zero 2 W (3 × 10 = 30)
Latência de Inferência t_{inf} (ms)
275
250
225
200
175
150
125
100
Mediana: 270.64 ms
(IQR: 0.24 ms | 3.69 FPS)
Mediana: 236.60 ms
(IQR: 0.71 ms | 4.21 FPS)
Mediana: 162.76 ms
(IQR: 0.14 ms | 6.14 FPS)
Mediana: 109.52 ms
(IQR: 0.25 ms | 9.09 FPS)
INT8 (4 Threads)
[Quad-Core]
INT8 (2 Threads)
[Dual-Core]
FP32 (4 Threads)
[Baseline Float32]
INT8 (1 Thread)
[Single-Core]
(b) Escalabilidade Multi-Core e Lei de Amdahl (E3b)
Speedup Ideal Linear ($S = N$)
Lei de Amdahl ($p = 79.38\%$, serial $= 20.62\%$)
Assíntota Máxima ($1/(1-p) = 4.85\times$)
Medições Empíricas (1, 2 e 4 Threads)
Speedup Relativo $S(N) = t(1)/t(N)$
1
2
3
4
5
$S(4) = 2.471\times$
$IC_{95\%\,BCa}$: [2.469; 2.473]
Mann-Whitney $p = 3,02 \times 10^{-11}$
δ de Cliff $= -1,00$
$S(2) = 1.663\times$
($p_{1\to2} = 79,7\%$)
1
2
3
4
5
6
7
8
Número de Núcleos / Threads (N)